Интеллектуальный анализ данных

Матричные разложения

Юрий Саночкин

ysanochkin@hse.ru

НИУ ВШЭ, 2026

Матричные разложения

- Теперь, когда мы с вами вспомнили и еще раз обсудили основные понятия линейной алгебры (которые понадобятся нам уже сегодня), мы можем, наконец, переходить к основному предмету нашего рассмотрения – матричным разложениям!

Матричные разложения

- Теперь, когда мы с вами вспомнили и еще раз обсудили основные понятия линейной алгебры (которые понадобятся нам уже сегодня), мы можем, наконец, переходить к основному предмету нашего рассмотрения – матричным разложениям!
- Давайте еще раз взглянем на общий вид матрицы признаков

Матрица признаков

- Матрицы признаков – прямоугольные вещественные матрицы размера $m \times n$, где:
  - m – размер выборки
  - n – количество признаков (и размер признакового пространства)

$$
\begin{array}{cc}
\begin{array}{ccccccc} \text{Feature-1} & \text{Feature-2} & \text{Feature-3} & \text{Feature-4} & & & \text{Feature-n} \end{array} & \\
\begin{bmatrix}
x_1^1 & x_2^1 & x_3^1 & x_4^1 & \dots & \dots & x_n^1 \\
x_1^2 & x_2^2 & x_3^2 & x_4^2 & \dots & \dots & x_n^2 \\
x_1^3 & x_2^3 & x_3^3 & x_4^3 & \dots & \dots & x_n^3 \\
\dots & \dots & \dots & \dots & \dots & \dots & \dots \\
x_1^m & x_2^m & x_3^m & x_4^m & \dots & \dots & x_n^m
\end{bmatrix} &
\begin{array}{l} \text{Sample-1} \\ \text{Sample-2} \\ \text{Sample-3} \\ \\ \text{Sample-m} \end{array}
\end{array}
$$

Матрица признаков

- Линейная алгебра — инструмент, который позволяет вам работать с данными огромной размерности.
- Пример:
- Типичная клетка опухоли в данных секвенирования — это 14000 чисел, а образец обычно содержит от ста до миллиона клеток.

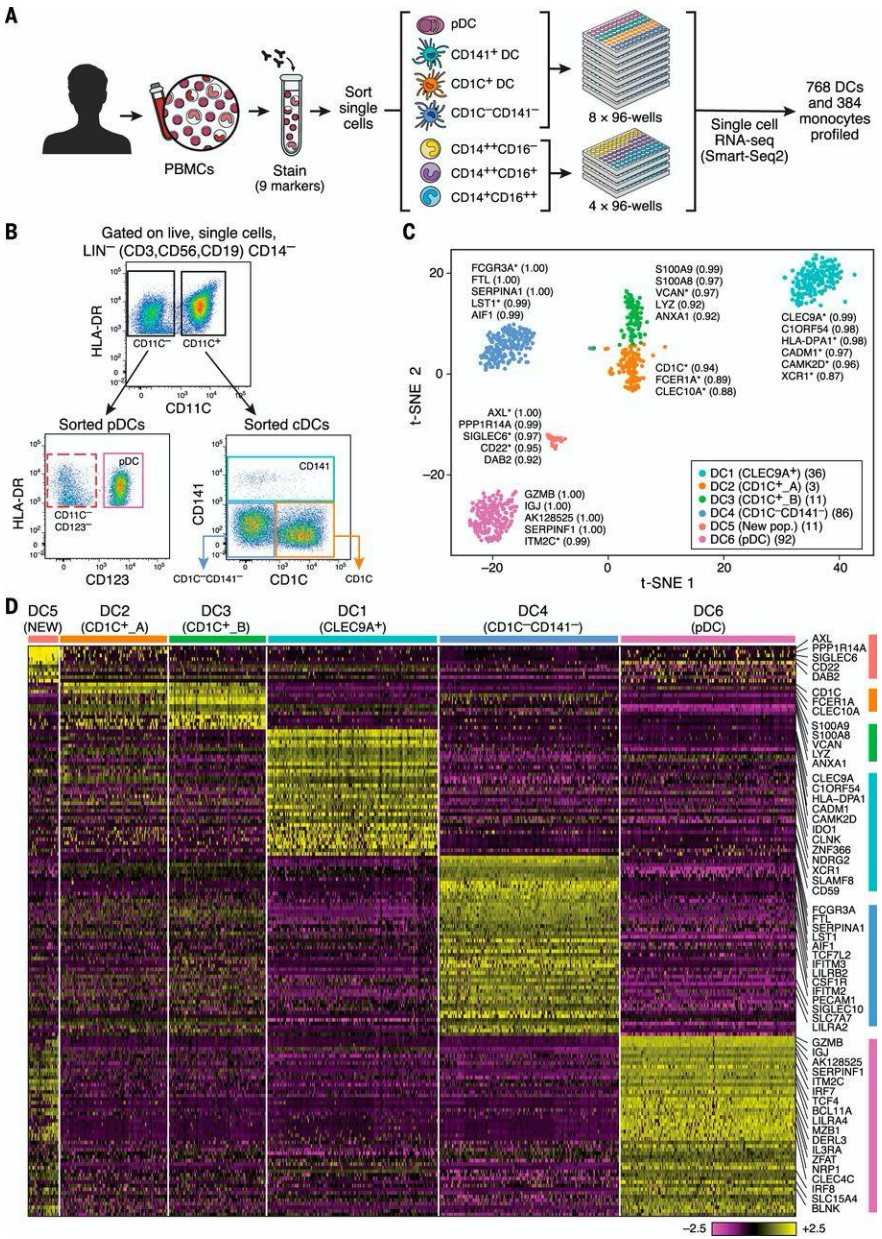

Матрица признаков

- Тем не менее, наш мозг не в состоянии воспринимать данные высокой размерности.
- Всё, что выше размерности 7 (длина, ширина, высота, три цвета, время) — практически за гранью нашего восприятия.
- Даже простейшие геометрические объекты в духе куба становится практически невозможно изобразить без потери информации.

Матрица признаков

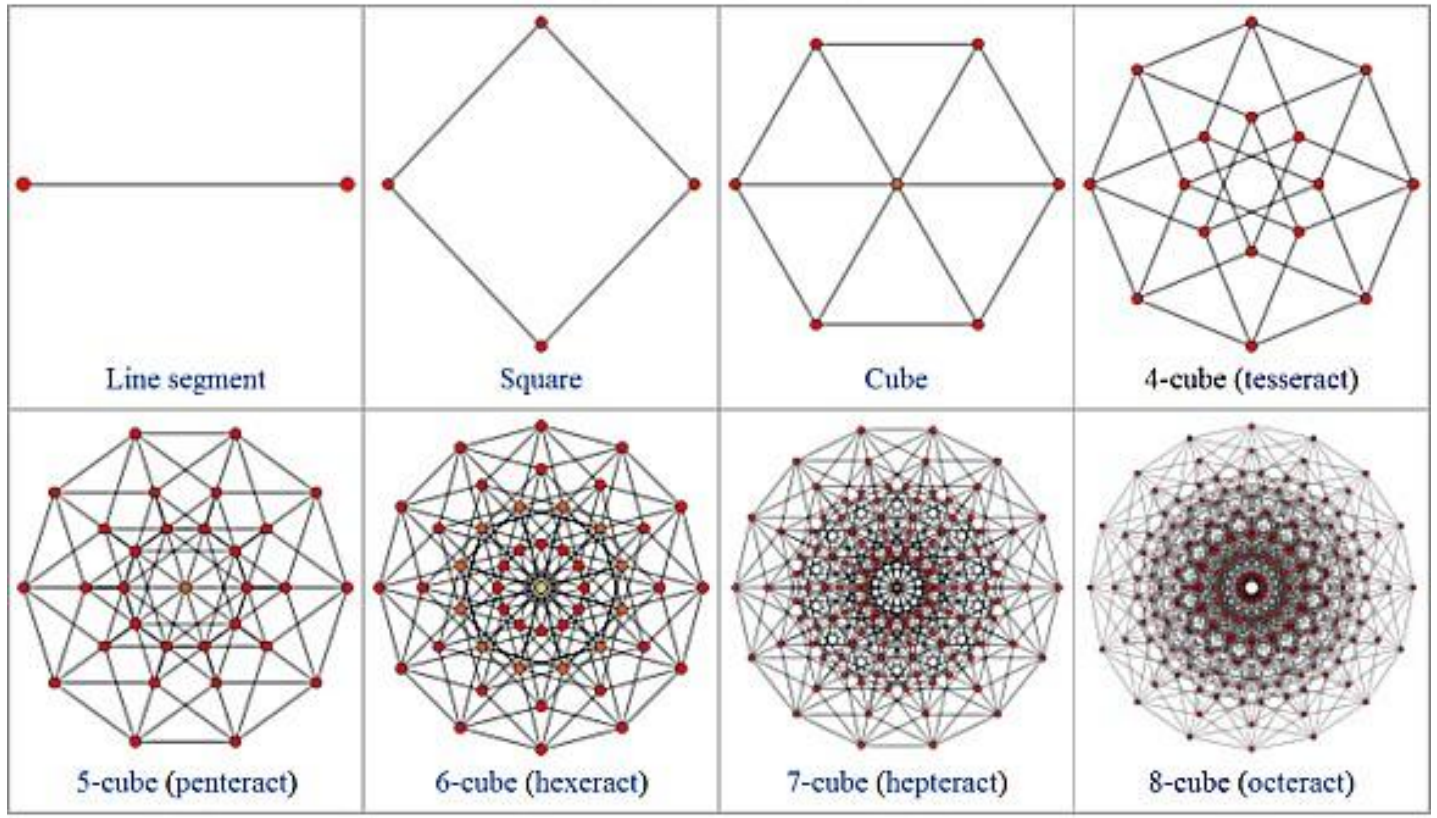

Укладка многомерных кубов (гиперкубов) на плоскости

Матрица признаков

- К счастью, реальные данные обычно лежат на т.н. маломерных многообразиях.
- Они не распределены по многомерному пространству равномерно, а лежат на поверхностях существенно меньшей размерности.

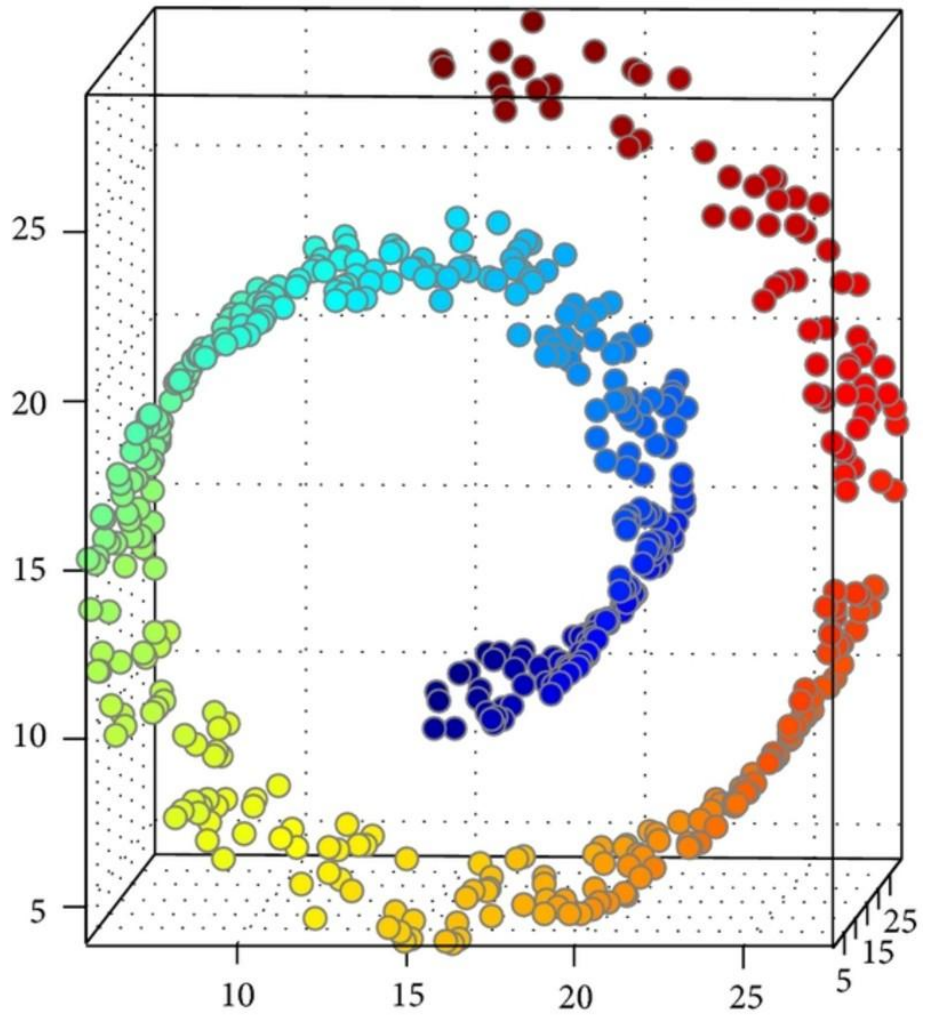

Матрица признаков

- К счастью, реальные данные обычно лежат на т.н. маломерных многообразиях.
- Они не распределены по многомерному пространству равномерно, а лежат на поверхностях существенно меньшей размерности.
- Обратите внимание на пример. Формально это трёхмерные данные, но по факту они почти полностью лежат на двумерной полосе!

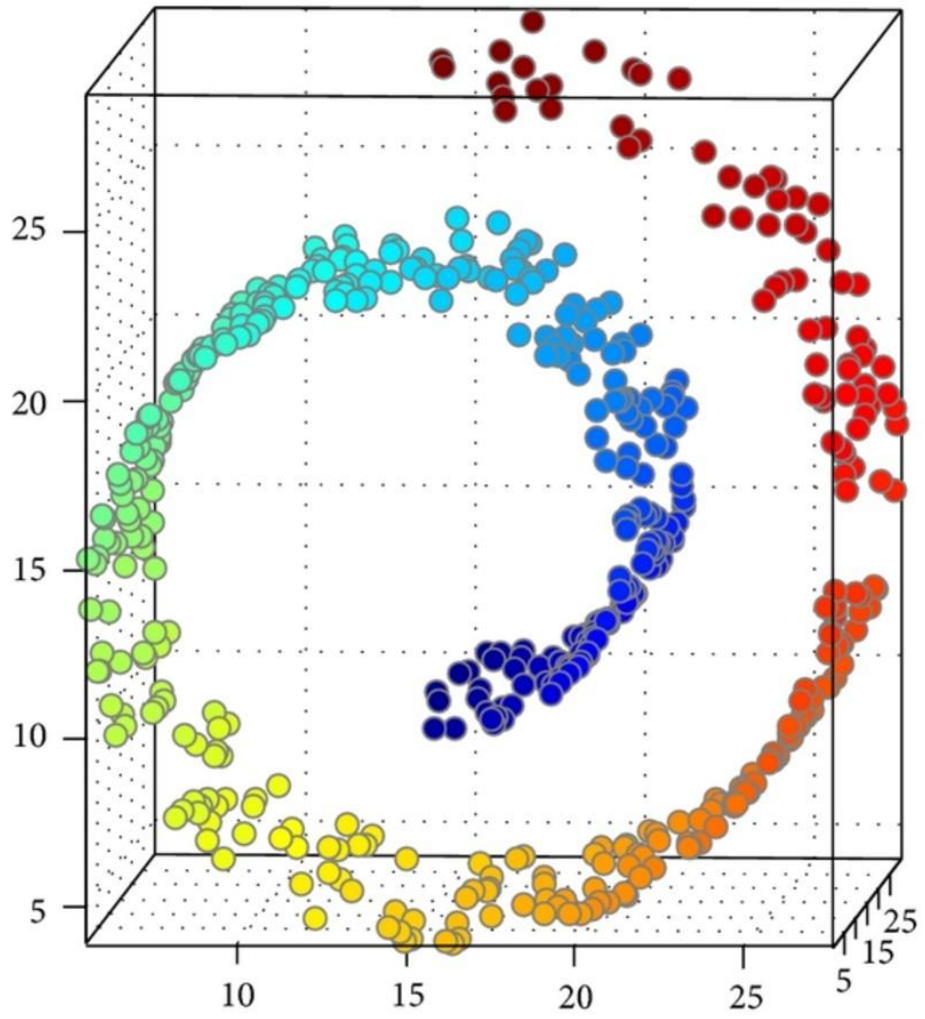

Матрица признаков

- Определением тонкой геометрической структуры данных занимается раздел ML под названием manifold learning.
- Но часто понизить размерность, скажем, с 14000 до 30-100 без существенной потери информации можно и при помощи более простых методов.
- Например, при помощи PCA — метода главных компонент, который ищет оптимальное приближение размерности для вашей матрицы данных.

Метод главных компонент (PCA)

- Алгоритм работы PCA можно описать следующими шагами:
  1. Найти такое направление в пространстве, вдоль которого дисперсия данных максимальна.
  2. Среди оставшихся направлений, ортогональных предыдущим, найти направление, вдоль которого дисперсия максимальна.
  3. Повторять шаг 2 до тех пор, пока это возможно.
- Получившиеся направления и называют главными компонентами.

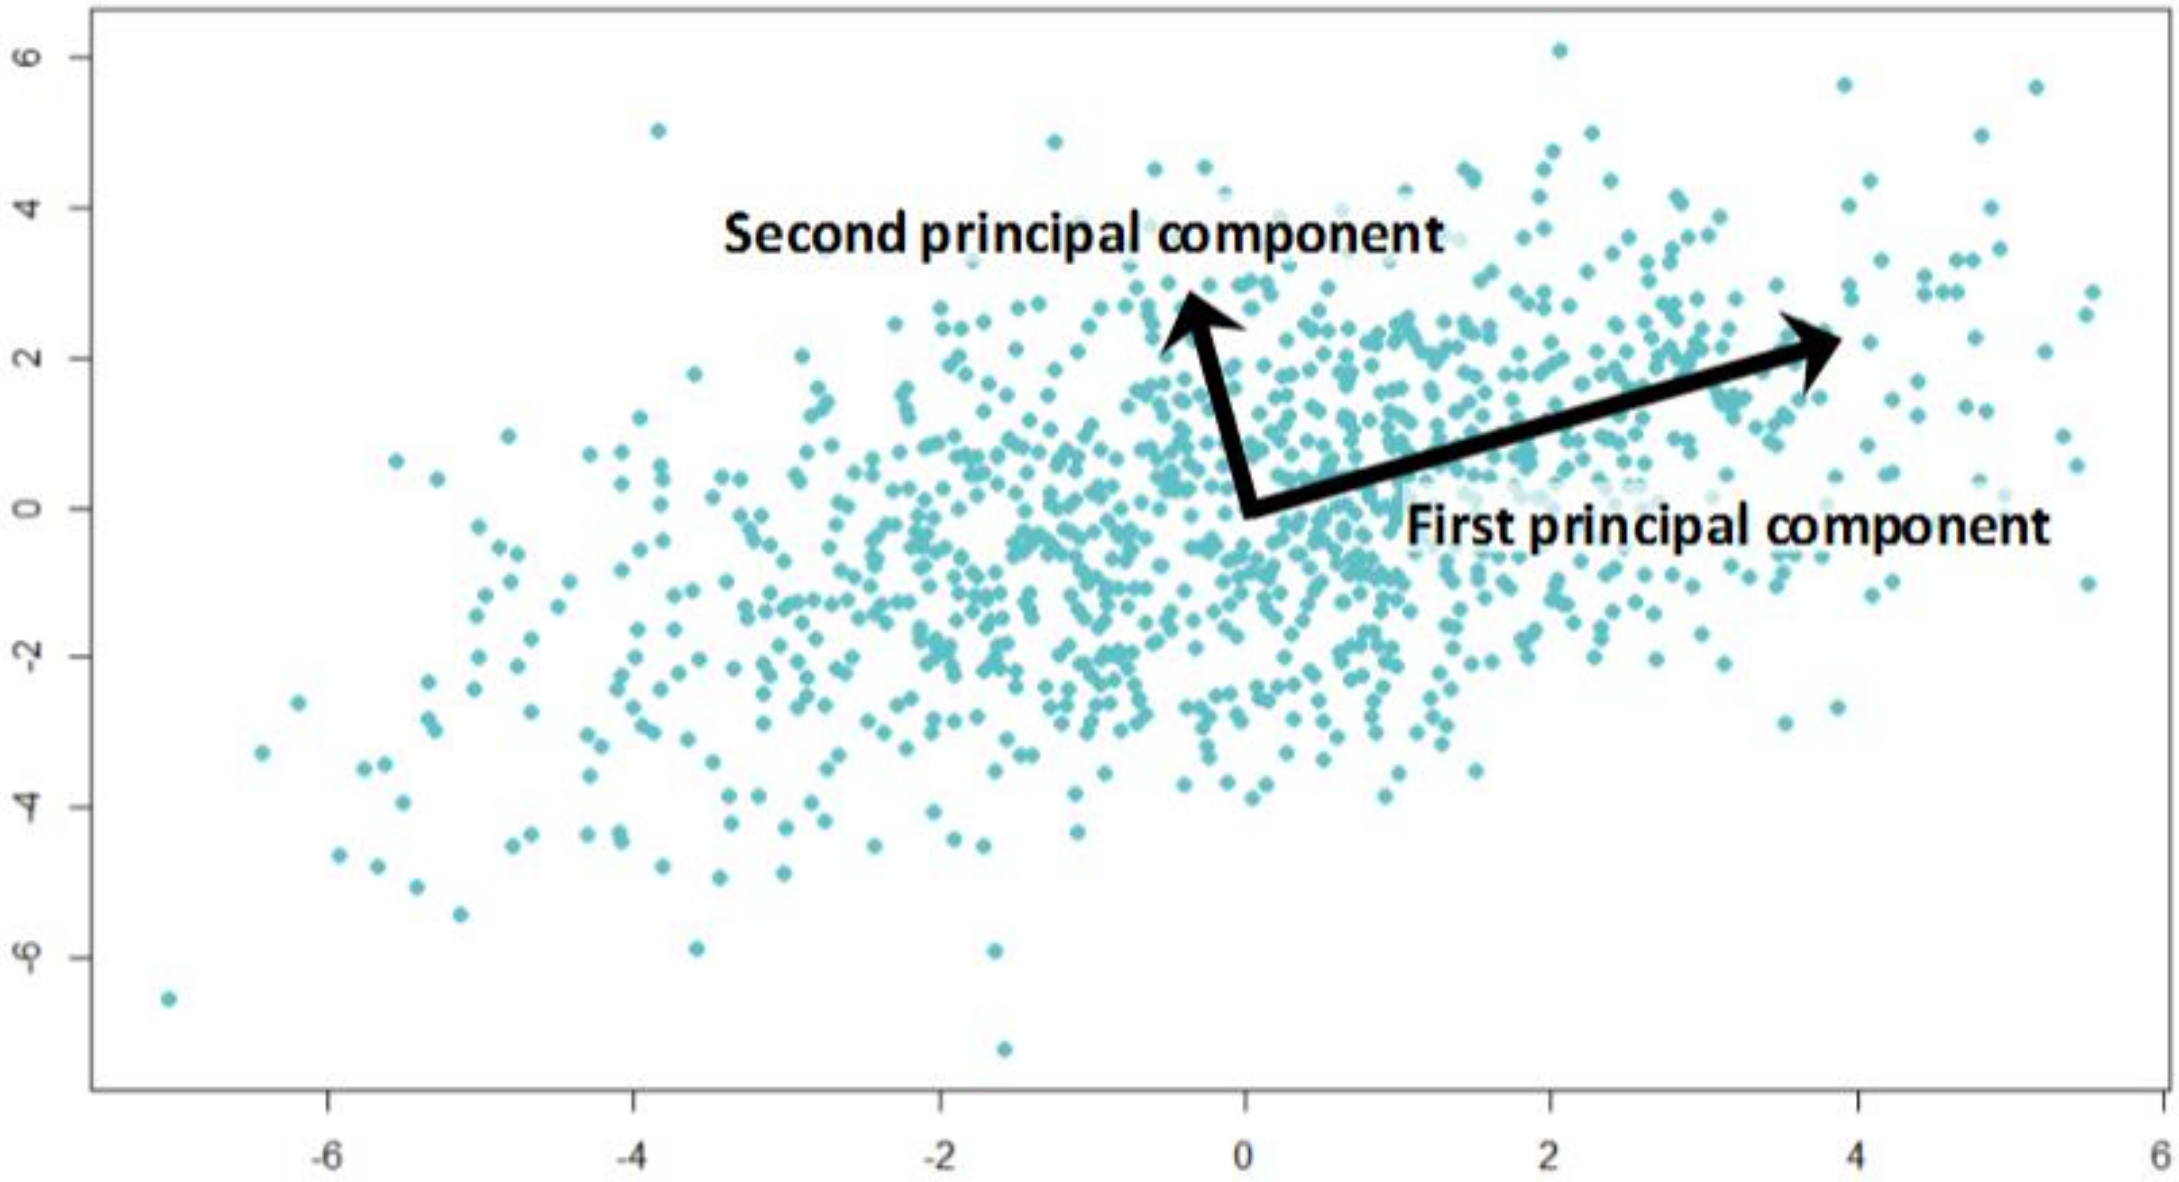
Second principal component
First principal component
6
4
2
0
-2
-4
-6
-6
-4
-2
0
2
4
6

Метод главных компонент (PCA)

- Но как искать такие направления?!

Метод главных компонент (PCA)

- Но как искать такие направления?!
- Мы могли бы находить такие направления полным перебором, но сколько бы это заняло времени хотя бы в 10-мерном пространстве?...

Метод главных компонент (PCA)

- Но как искать такие направления?!
- Мы могли бы находить такие направления полным перебором, но сколько бы это заняло времени хотя бы в 10-мерном пространстве?...
- Поэтому мы, как настоящие математики, воспользуемся доступным мат. аппаратом, чтобы решить эту задачу!

Важные понятия линейной алгебры

- Ортогональная матрица – такая матрица, для которой обратная матрица совпадает с транспонированной.

$$A \cdot A^T = A \cdot A^{-1} = I$$

$$\begin{pmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix}$$

Важные понятия линейной алгебры

- Сингулярные направления и значения:
- где
  - v – правый сингулярный вектор,
  - u – левый сингулярный вектор,
  - σ – сингулярное значение.
- Сингулярное значение это корень из собственного значения матрицы $M^T M$

$$Mv = \sigma u$$
$$M^T u = \sigma v$$

Важные понятия линейной алгебры

- Сингулярные направления и значения:
- где
  - v – правый сингулярный вектор,
  - u – левый сингулярный вектор,
  - σ – сингулярное значение.
- Сингулярное значение это корень из собственного значения матрицы $M^T M$

$$Mv = \sigma u$$
$$M^T u = \sigma v$$

Сингулярные вектора и значения это в некотором смысле аналоги собственных векторов и чисел для неквадратных матриц. Причем, если матрица квадратная, то квадрат сингулярного значения равен модулю соответствующего собственного значения (если такое существует).

Сингулярное матричное разложение (SVD)

- Так вот оказывается, что любую матрицу M можно разложить в произведение трех таких матриц U , Σ и V^T, что:

Сингулярное матричное разложение (SVD)

- Так вот оказывается, что любую матрицу M можно разложить в произведение трех таких матриц U , Σ и V^T, что:

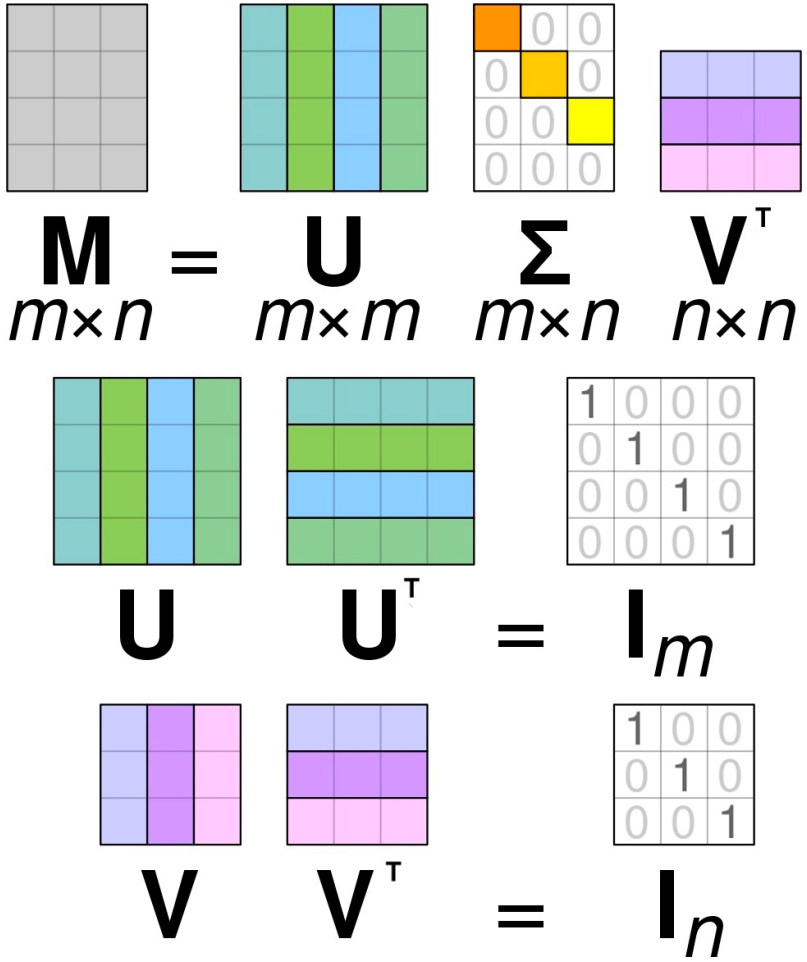

Сингулярное матричное разложение (SVD)

- Так вот оказывается, что любую матрицу M можно разложить в произведение трех таких матриц U , Σ и V^T, что:
  - $M \in \mathbb{R}^{m \times n}$ — Исходная матрица;
  - $U \in \mathbb{R}^{m \times m}$ — Матрица левых сингулярных векторов;
  - $\Sigma \in \mathbb{R}^{m \times n}$ — Матрица, на главной диагонали которой находятся т.н. сингулярные числа (в порядке невозрастания);
  - $V \in \mathbb{R}^{n \times n}$ — Матрица правых сингулярных векторов.

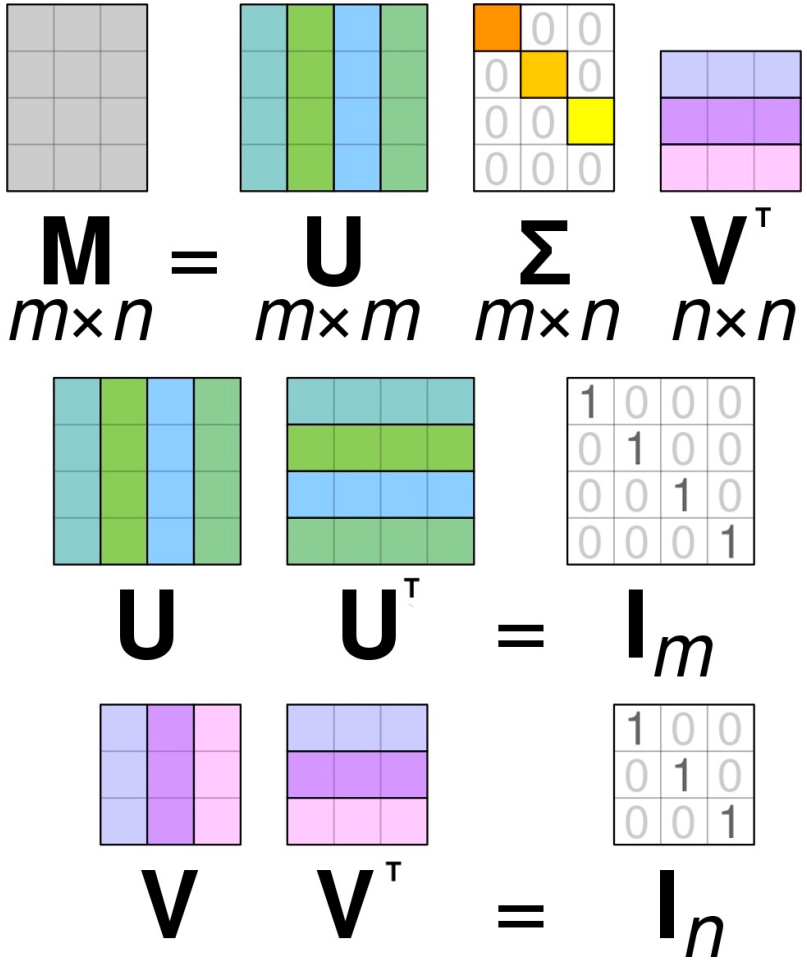

Сингулярное матричное разложение (SVD)

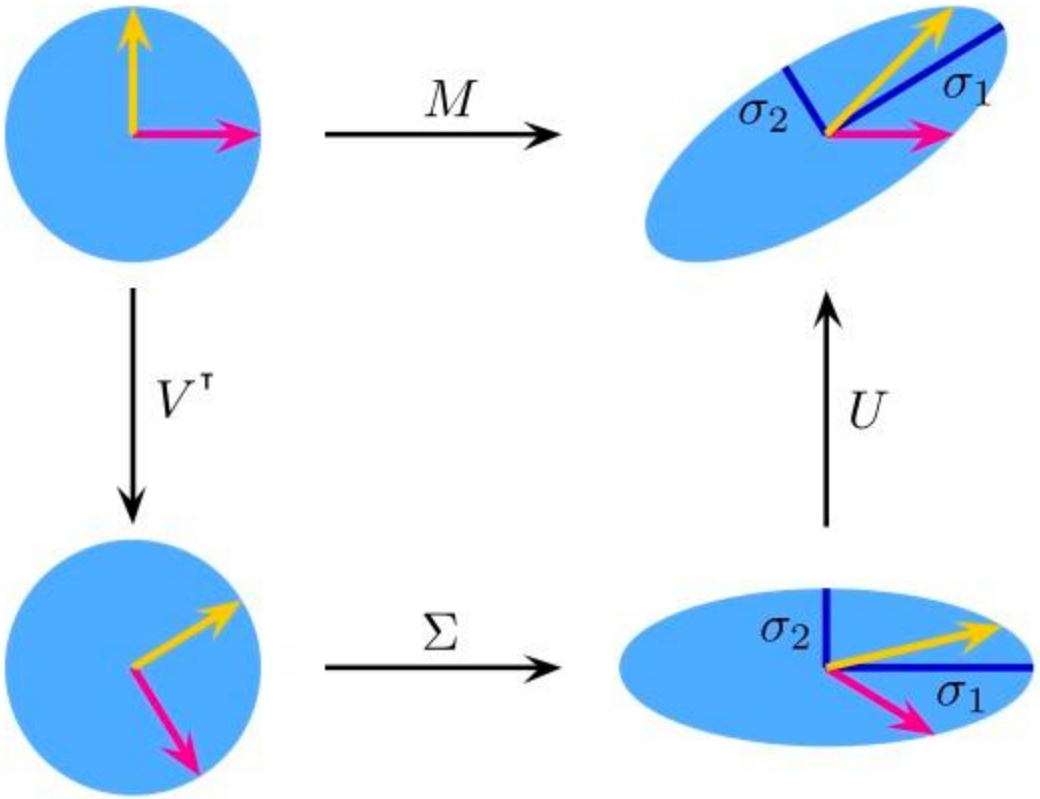

$$M = U \cdot \Sigma \cdot V^\intercal$$

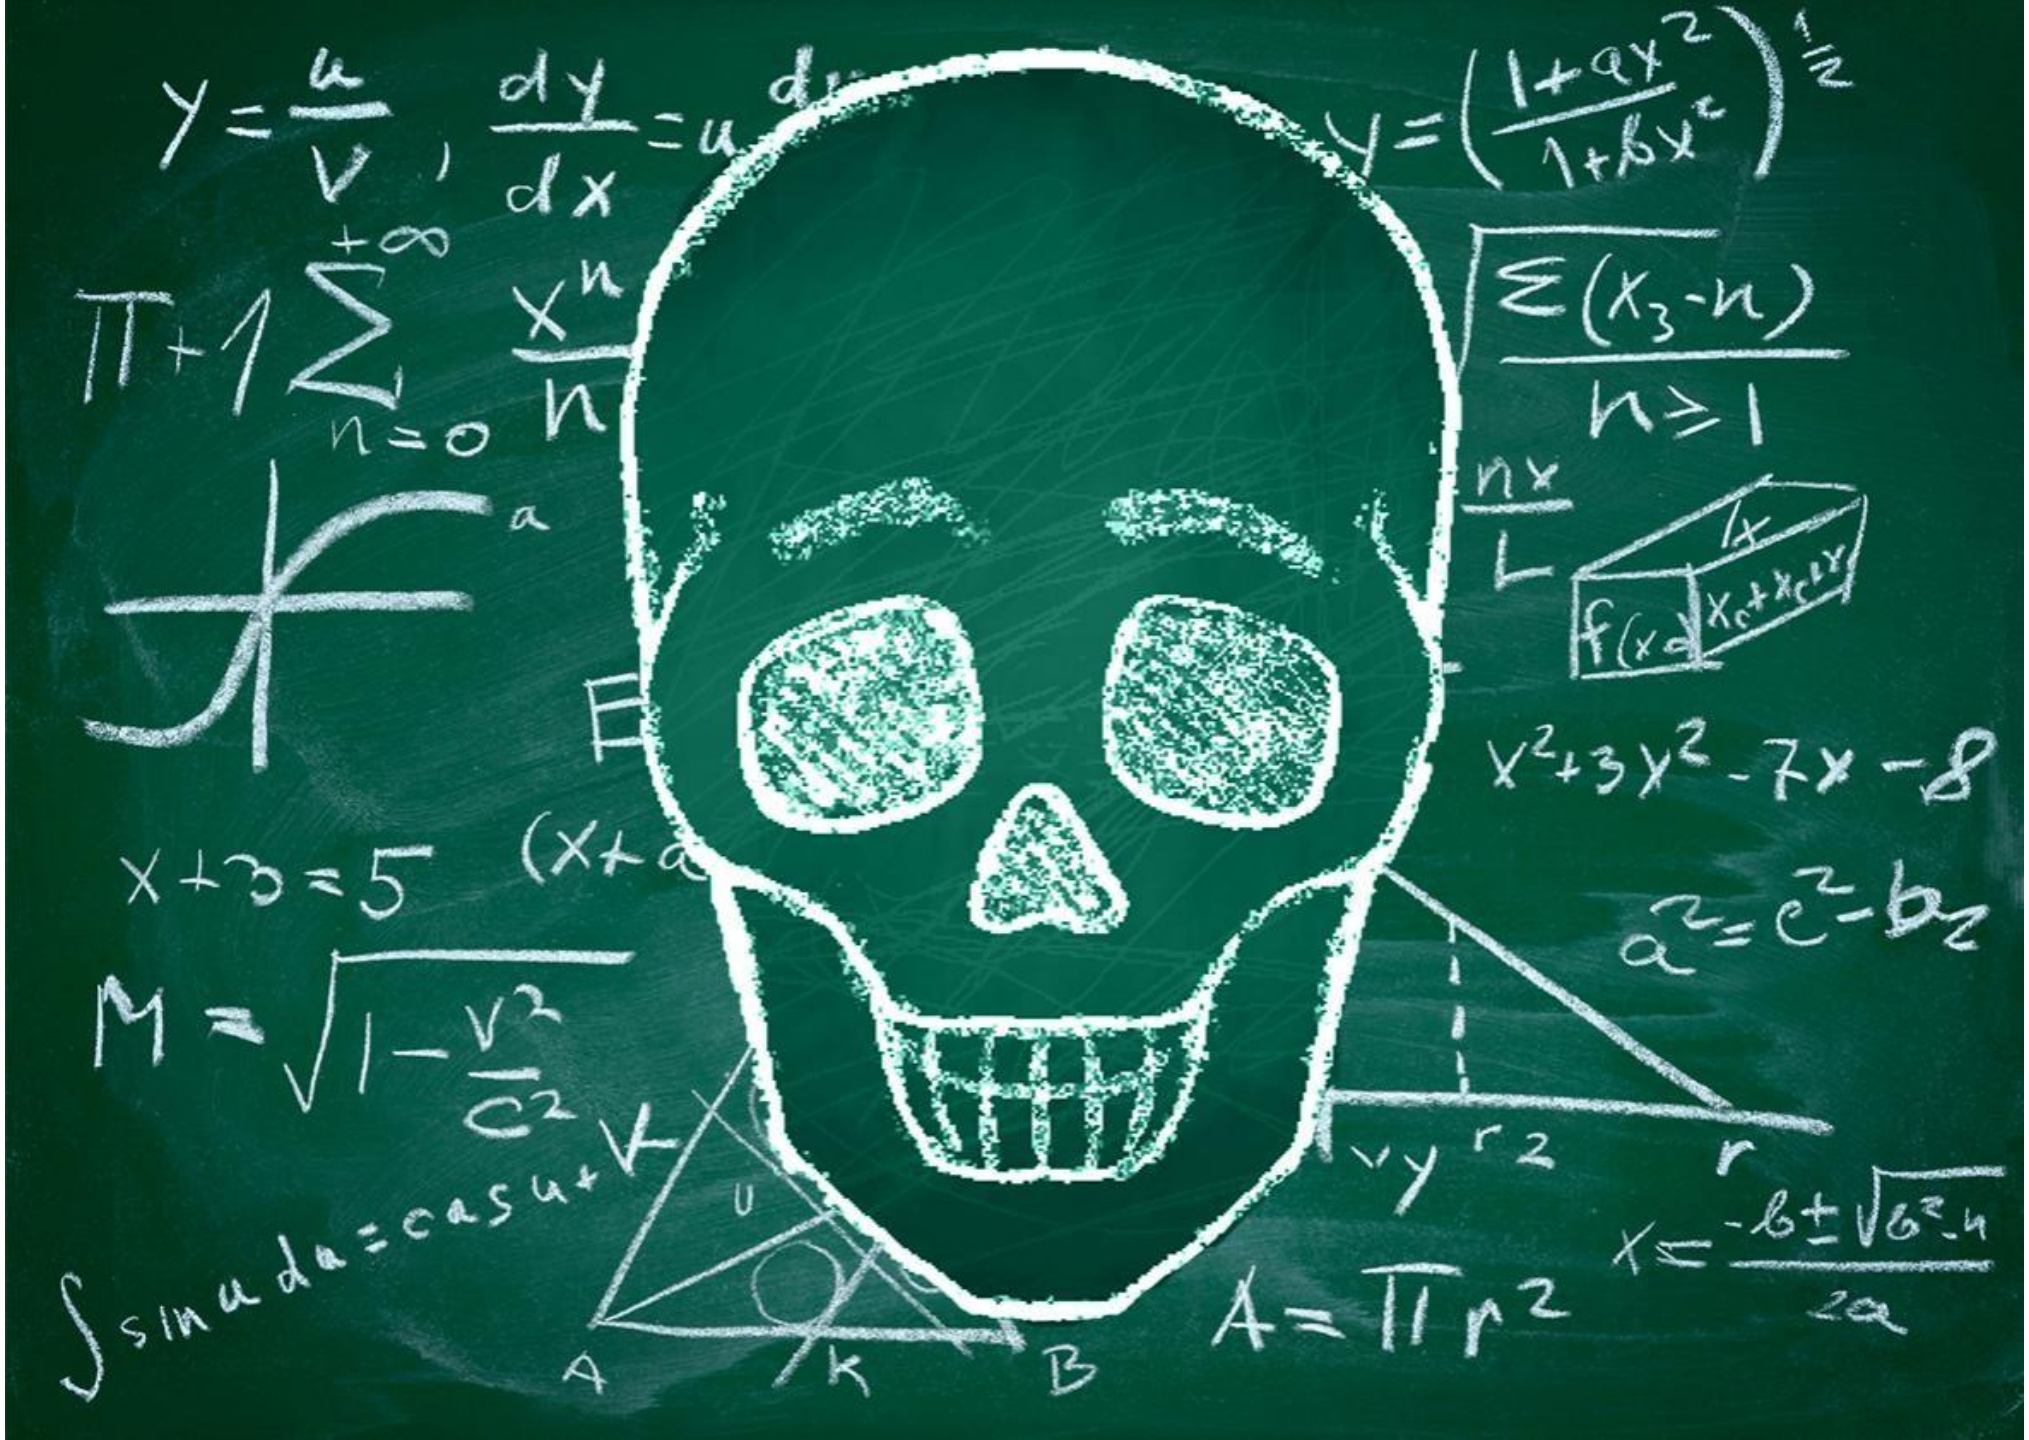
x+3=5
M = √(1 − v²/c²)
∫ sin u du = cos u + V
A = πr²
x² + 3x² − 7x − 8
a² = c² − b²
A
B
K
U
r
r2

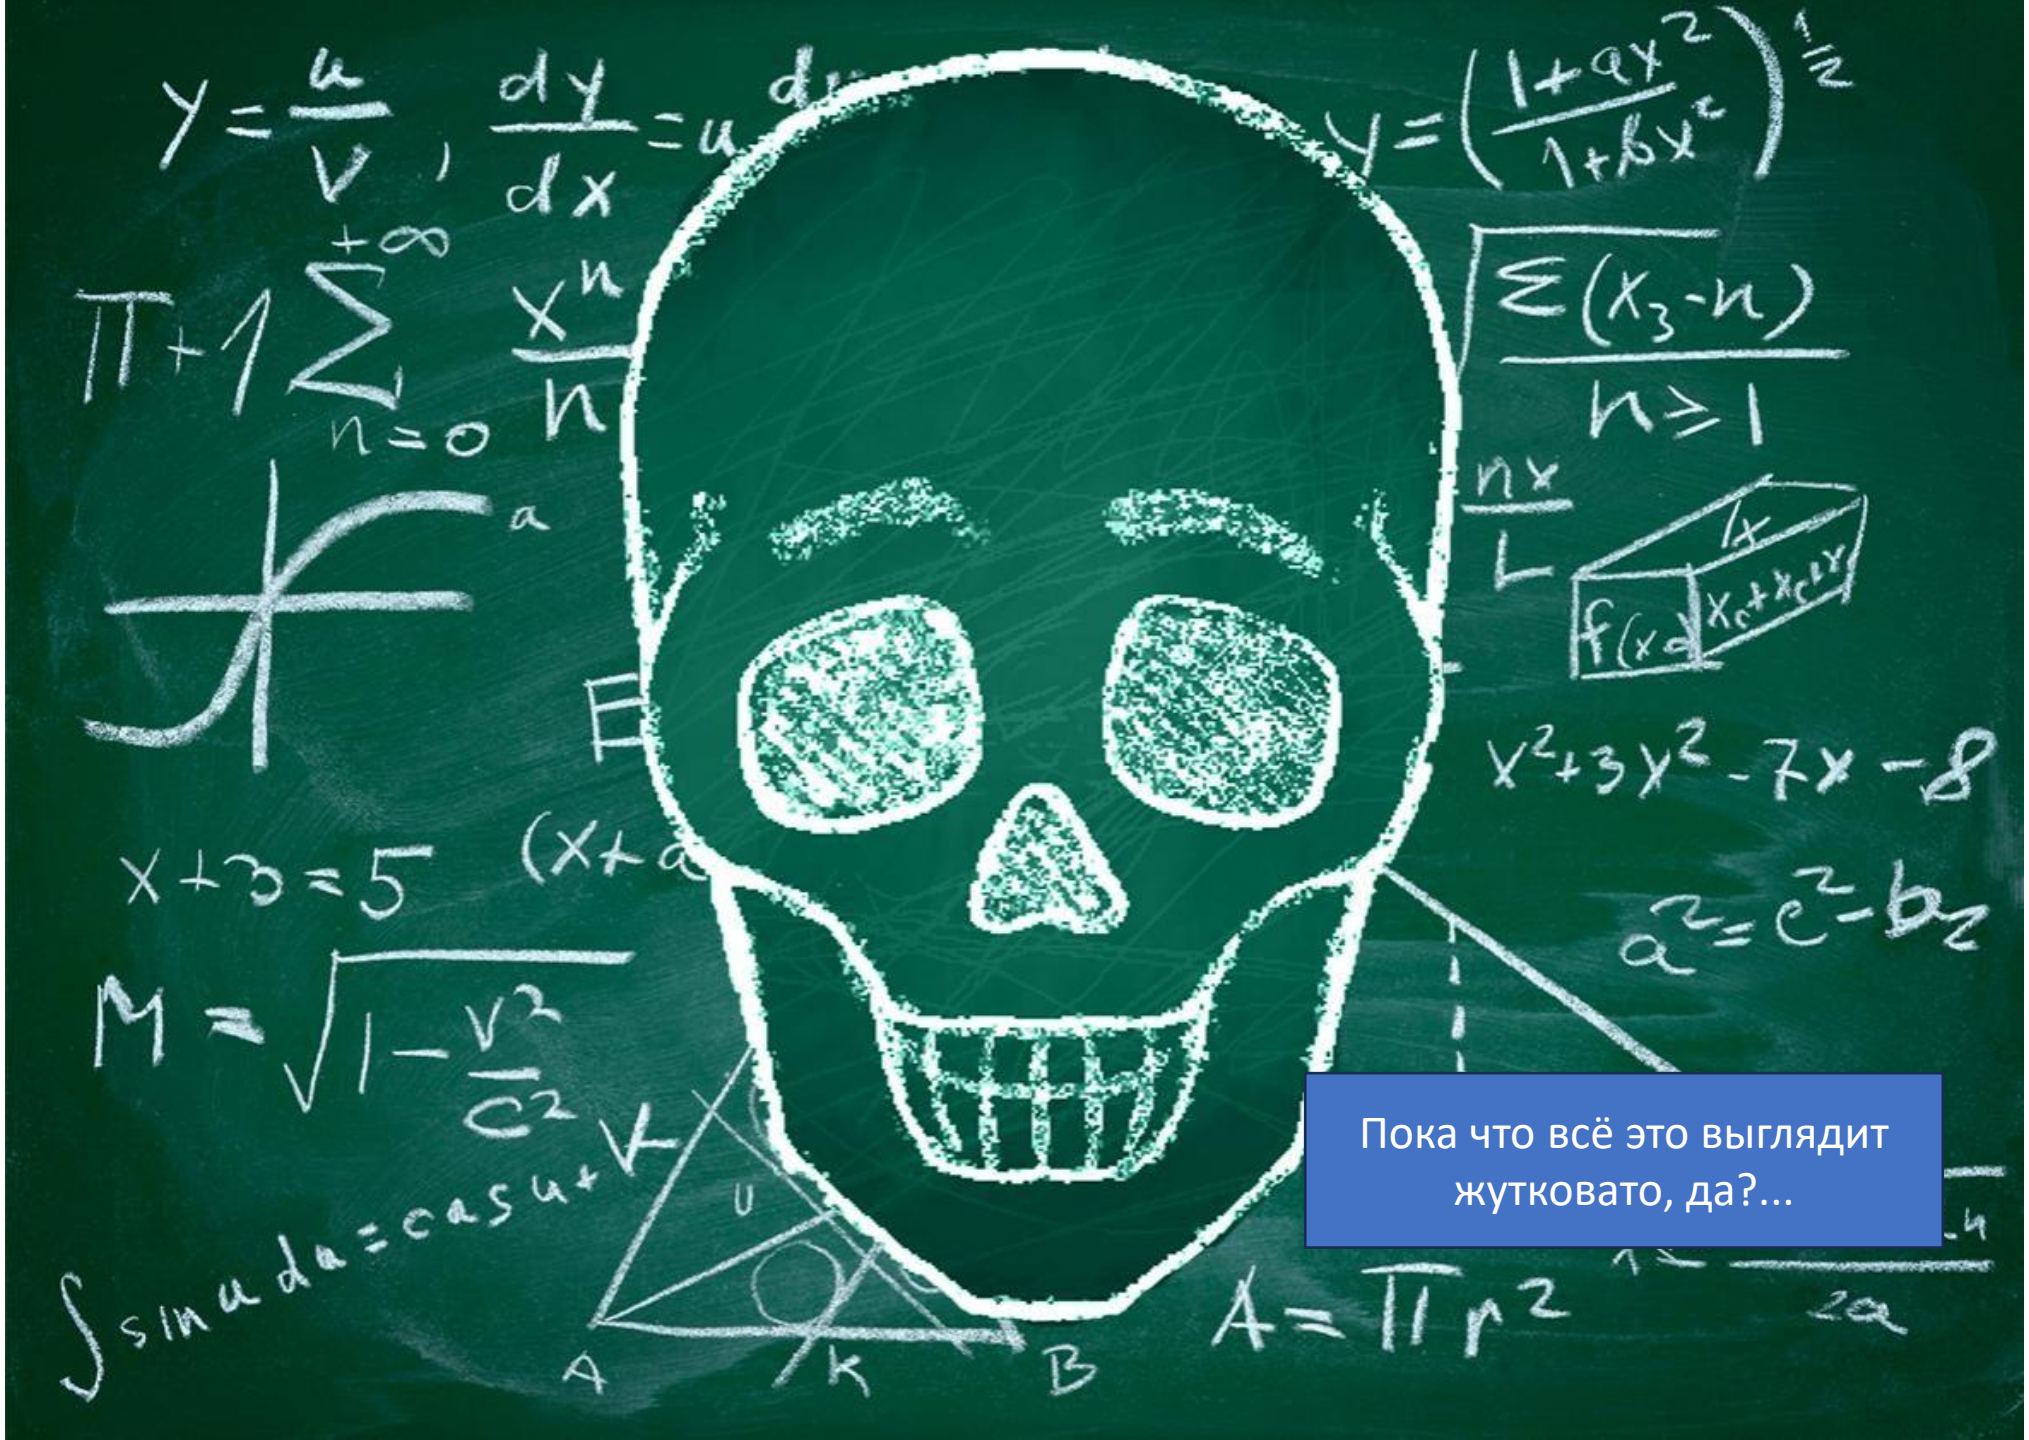
Пока что всё это выглядит жутковато, да?...

Усечённое SVD-разложение ранга r

- Усечённое SVD-разложение ранга r матрицы $M \in \mathbb{R}^{m \times n}$ — это обычное SVD-разложение, где оставили только самые большие сингулярные значения вместе с соответствующими сингулярными векторами.

Усечённое SVD-разложение ранга r

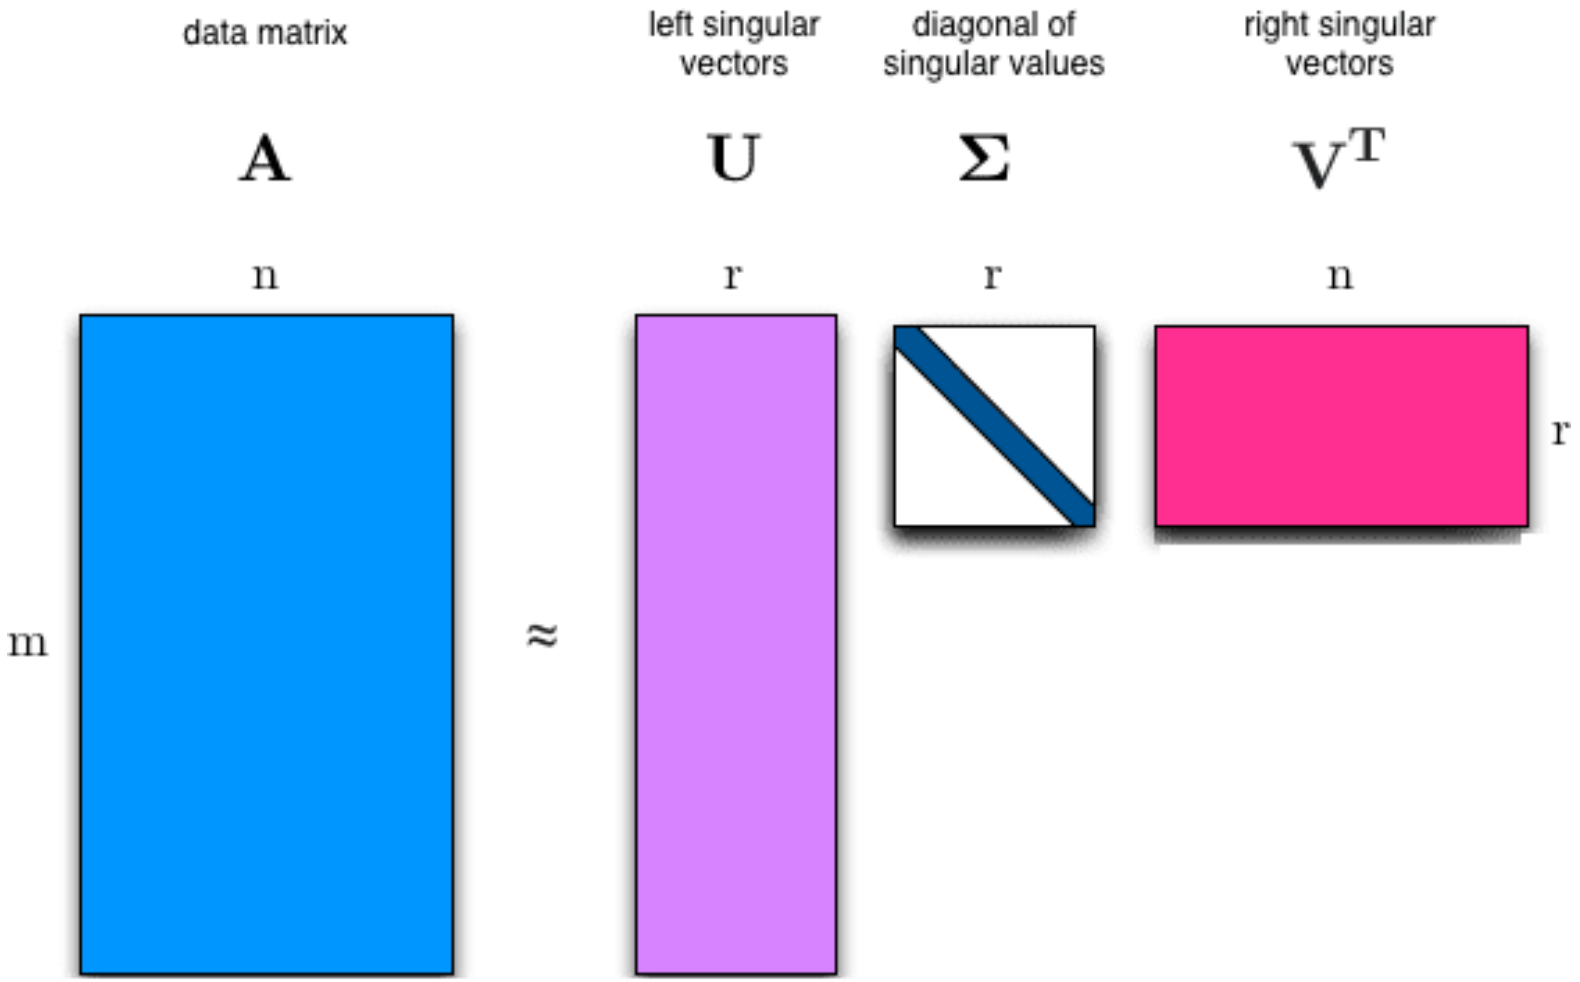

Усечённое SVD-разложение ранга r

- Усечённое SVD-разложение ранга r матрицы $M \in \mathbb{R}^{m \times n}$ — это обычное SVD-разложение, где оставили только самые большие сингулярные значения вместе с соответствующими сингулярными векторами.

Усечённое SVD-разложение ранга r

- Усечённое SVD-разложение ранга r матрицы $M \in \mathbb{R}^{m \times n}$ — это обычное SVD-разложение, где оставили только самые большие сингулярные значения вместе с соответствующими сингулярными векторами.
- Можно доказать, что усечённое SVD-разложение ранга r это оптимальная по Фробениусовой норме аппроксимация ранга r.

Усечённое SVD-разложение ранга r

- Усечённое SVD-разложение ранга r матрицы $M \in \mathbb{R}^{m \times n}$ — это обычное SVD-разложение, где оставили только самые большие сингулярные значения вместе с соответствующими сингулярными векторами.
- Можно доказать, что усечённое SVD-разложение ранга r это оптимальная по Фробениусовой норме аппроксимация ранга r.

Усечённое SVD-разложение ранга r

- Усечённое SVD-разложение ранга r матрицы $M \in \mathbb{R}^{m \times n}$ — это обычное SVD-разложение, где оставили только самые большие сингулярные значения вместе с соответствующими сингулярными векторами.
- Можно доказать, что усечённое SVD-разложение ранга r это оптимальная по Фробениусовой норме аппроксимация ранга r.

Норма Фробениуса, или евклидова норма (для евклидова пространства), представляет собой частный случай p-нормы для $p = 2$:

$$\|A\|_F = \sqrt{\sum_{i=1}^{m} \sum_{j=1}^{n} |a_{ij}|^2}$$

Усечённое SVD-разложение ранга r

- Усечённое SVD-разложение ранга r матрицы $M \in \mathbb{R}^{m \times n}$ — это обычное SVD-разложение, где оставили только самые большие сингулярные значения вместе с соответствующими сингулярными векторами.
- Можно доказать, что усечённое SVD-разложение ранга r это оптимальная по Фробениусовой норме аппроксимация ранга r.
- Поздравляю, именно благодаря этому факту мы можем финализировать алгоритм метода главных компонент! :)

Связь SVD и PCA

- PCA-преобразование можно было бы делать при помощи нахождения собственных векторов (как на алгоритме справа), но к сожалению почти всегда наши датасеты имеют разное число строк и столбцов, и поэтому мы вынуждены использовать SVD.

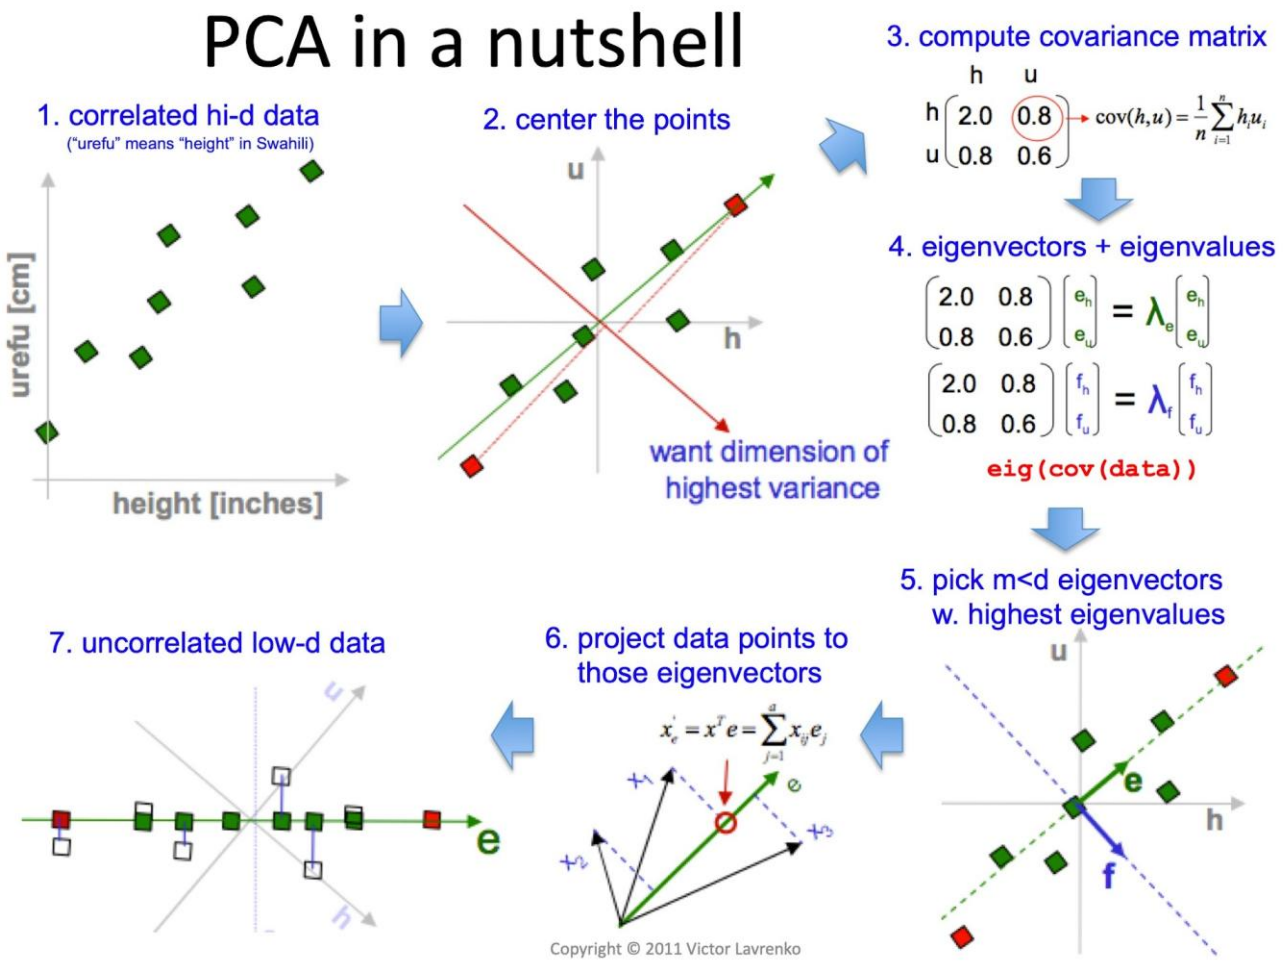

Связь SVD и PCA

- Но есть и хорошая новость! Для того, чтобы получить PCA-преобразование, достаточно всего лишь посчитать $U\Sigma$, то есть произведение первых двух матриц в разложении SVD.

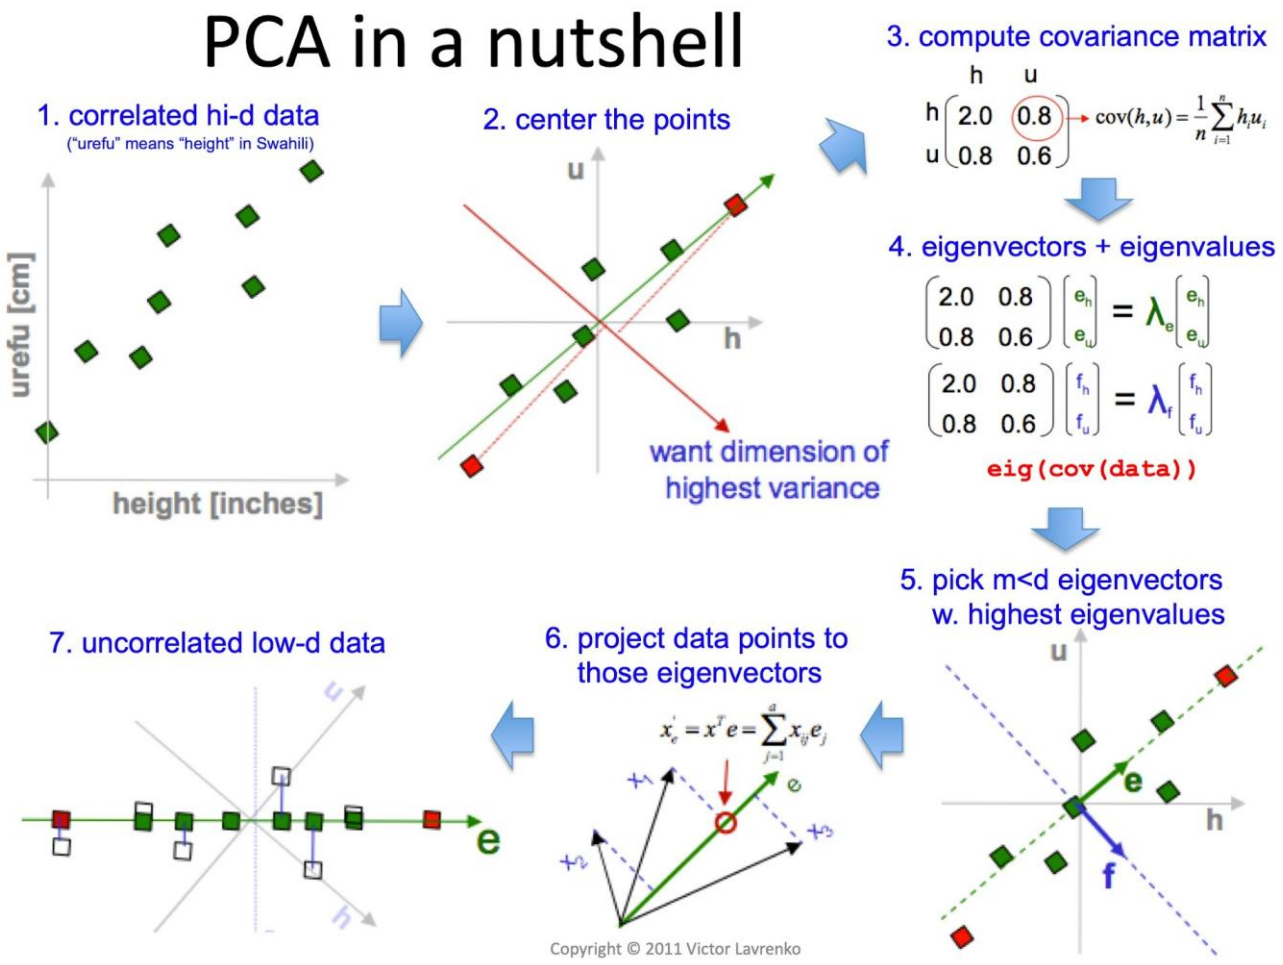

Связь SVD и PCA

- Но есть и хорошая новость! Для того, чтобы получить PCA-преобразование, достаточно всего лишь посчитать $U\Sigma$, то есть произведение первых двух матриц в разложении SVD.
- Подробнее – обязательно разберем на семинарах!

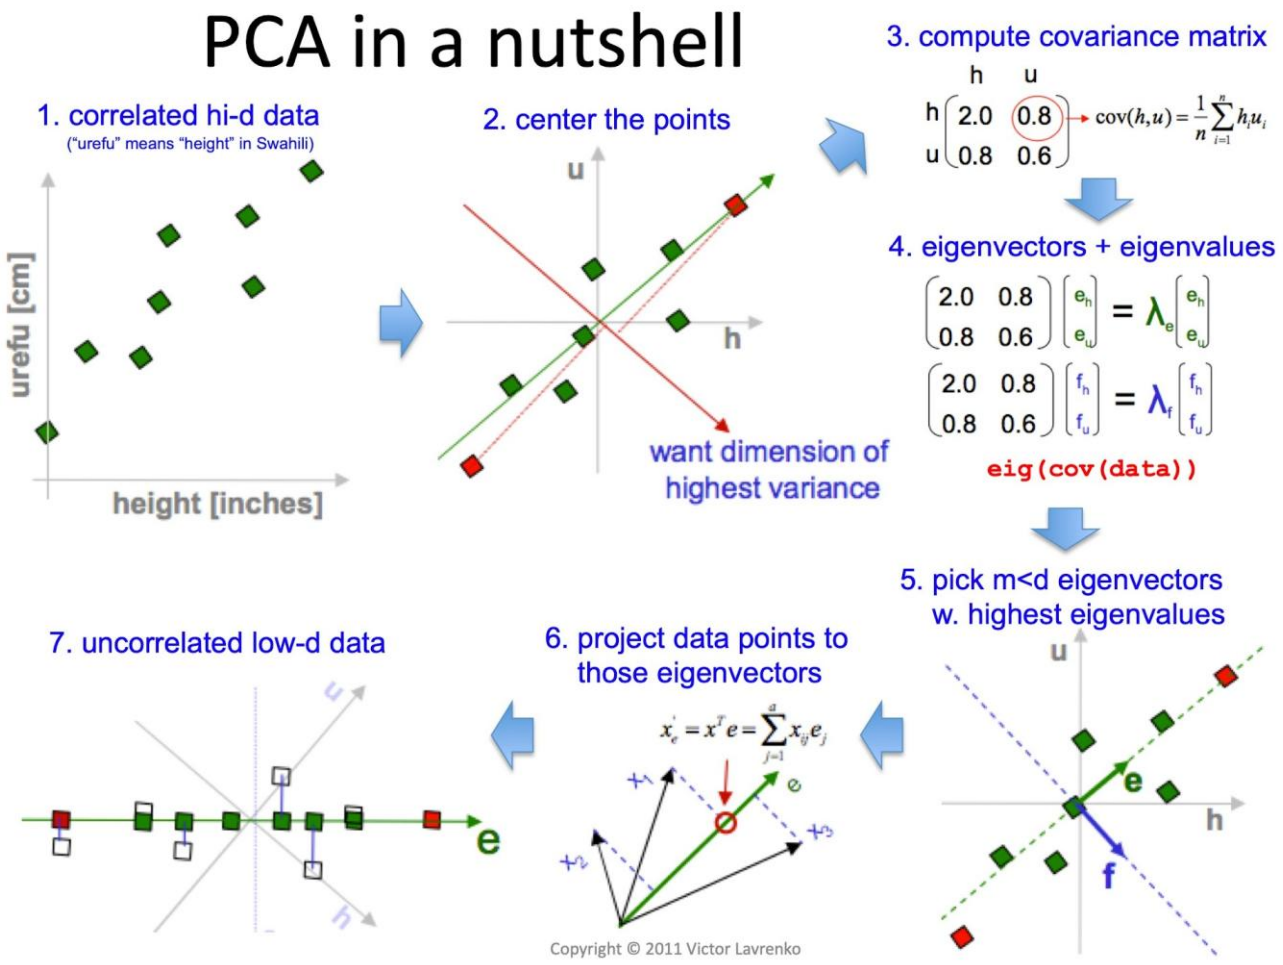

Связь SVD и PCA

- Конкурентное преимущество SVD-разложения в том, что для его вычисления есть эффективные алгоритмы.
- В том числе для огромных разреженных матриц, которые часто встречаются на практике (в рекомендательных системах, биоинформатике etc).

Связь SVD и PCA

- Конкурентное преимущество SVD-разложения в том, что для его вычисления есть эффективные алгоритмы.
- В том числе для огромных разреженных матриц, которые часто встречаются на практике (в рекомендательных системах, биоинформатике etc).

Упрощённая схема вычисления SVD-разложения.
На каждый случай — свой алгоритм!
И это ещё — без учёта разреженности матрицы.

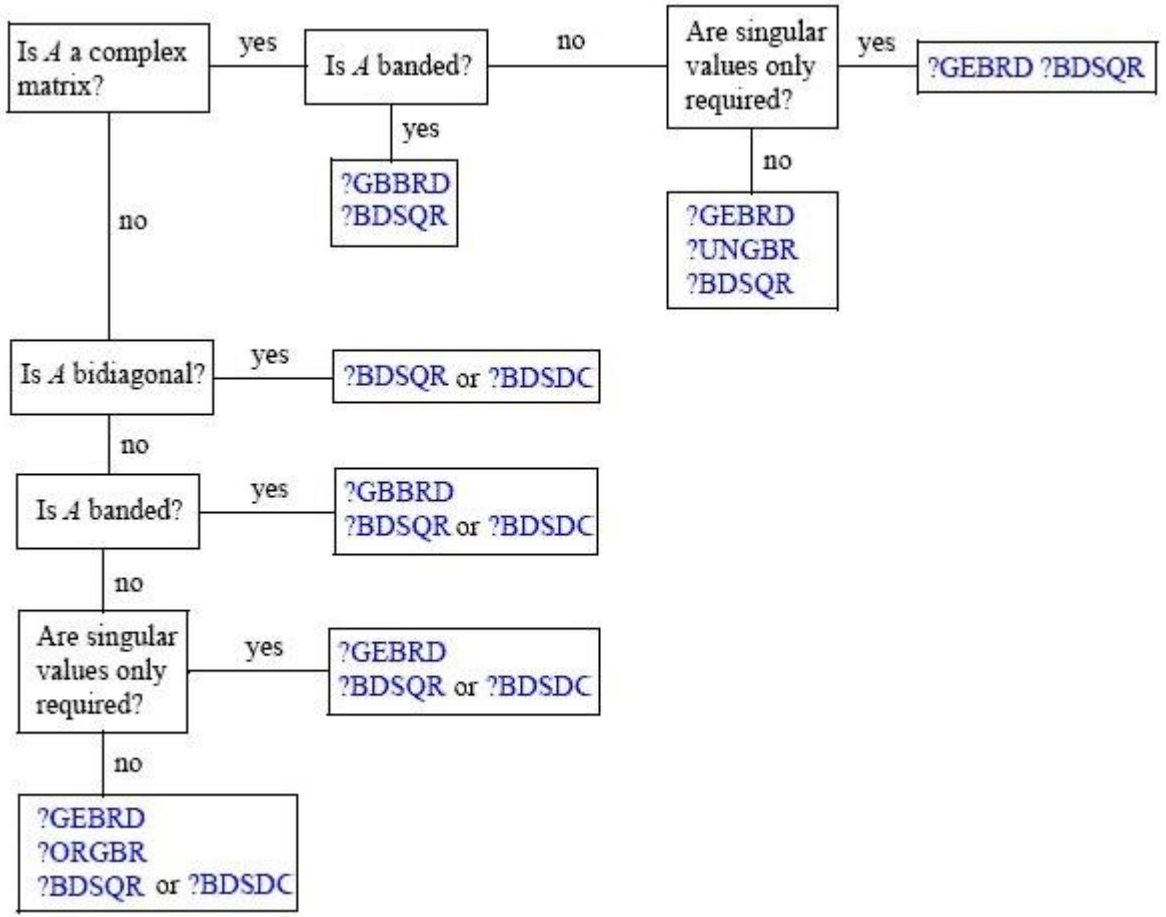

Связь SVD и PCA

- Конкурентное преимущество SVD-разложения в том, что для его вычисления есть эффективные алгоритмы.
- В том числе для огромных разреженных матриц, которые часто встречаются на практике (в рекомендательных системах, биоинформатике etc).
- Но не PCA единым хорош SVD!

Приложения SVD

Приложения SVD

- В задачах построения рекомендательных систем важную роль играет матрица взаимодействий пользователя с контентом.

	Harry Potter	The Triplets of Belleville	Shrek	The Dark Knight Rises	Memento
■	.9	-.8	1	1	-.9
▲	-.2	-.8	-1	.9	1

●	◆		Harry Potter	The Triplets of Belleville	Shrek	The Dark Knight Rises	Memento
1	.1		✓		✓	✓	
-1	0			✓			✓
.2	-1		✓	✓	✓		
.1	1				?	✓	✓

■ arthouse <-> blockbuster

▲ children's <-> adult's

● preference for arthouse <-> blockbuster

◆ preference for children's <-> adult's

Приложения SVD

- В задачах построения рекомендательных систем важную роль играет матрица взаимодействий пользователя с контентом.
- Представьте Netflix (хорошо нам знакомый):

Приложения SVD

- В задачах построения рекомендательных систем важную роль играет матрица взаимодействий пользователя с контентом.
- Представьте Netflix (хорошо нам знакомый):
  - Миллионы пользователей;
  - Тысячи фильмов и сериалов;
  - Каждый пользователь, в среднем, смотрит < 100 из них.

Приложения SVD

- В задачах построения рекомендательных систем важную роль играет матрица взаимодействий пользователя с контентом.
- Представьте Netflix (хорошо нам знакомый):
  - Миллионы пользователей;
  - Тысячи фильмов и сериалов;
  - Каждый пользователь, в среднем, смотрит < 100 из них.
- Что можно сказать о матрице оценок?

Приложения SVD

- В задачах построения рекомендательных систем важную роль играет матрица взаимодействий пользователя с контентом.
- Представьте Netflix (хорошо нам знакомый):
  - Миллионы пользователей;
  - Тысячи фильмов и сериалов;
  - Каждый пользователь, в среднем, смотрит < 100 из них.
- Что можно сказать о матрице оценок?
- Гигантская разреженная матрица. На пересечении (пользователь, столбец) — оценка или любая другая полезная информация (“посмотрел ли до конца” и другие прокси-метрики)

Приложения SVD

- Усеченное SVD-разложение ранга r матрицы взаимодействий позволяет получить эмбеддинги размерности r как для пользователей, так и для контента!

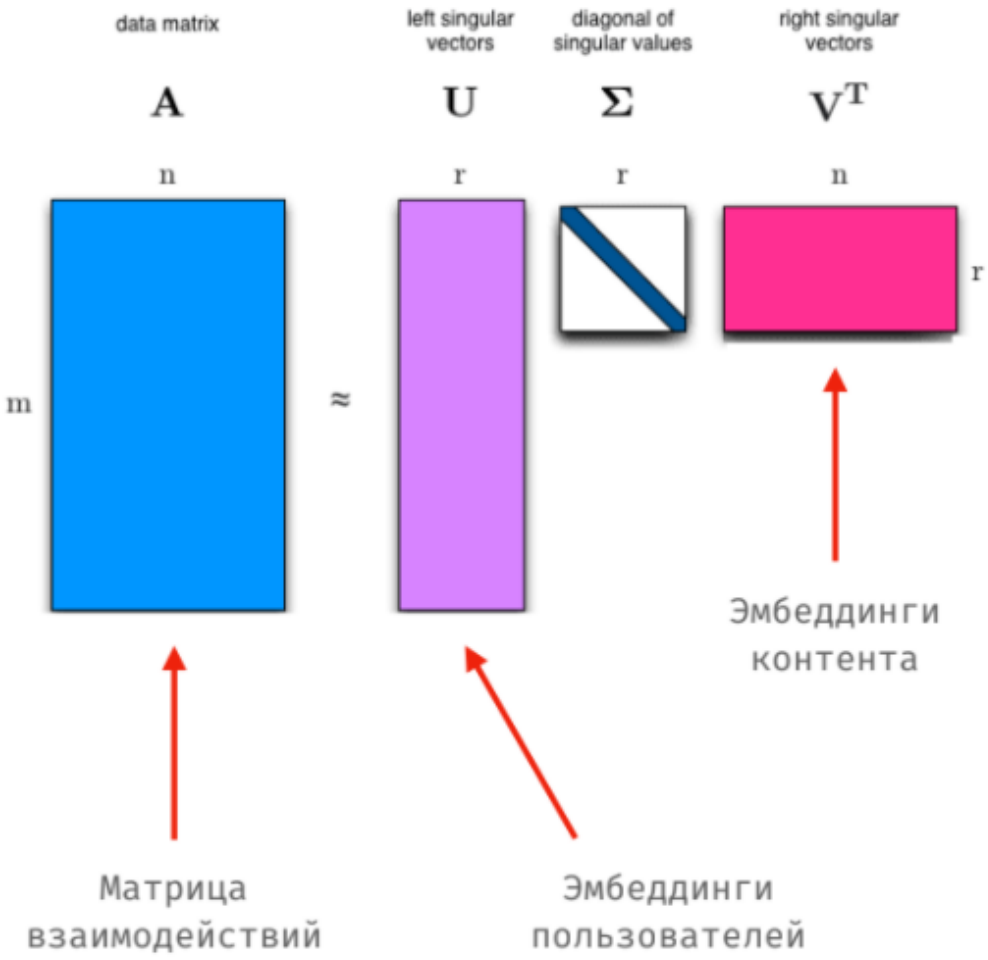

Приложения SVD

- Усеченное SVD-разложение ранга r матрицы взаимодействий позволяет получить эмбеддинги размерности r как для пользователей, так и для контента!
- Более того: чем больше скалярное произведение эмбеддингов пользователя и контента, тем выше шанс, что пользователю понравится контент!

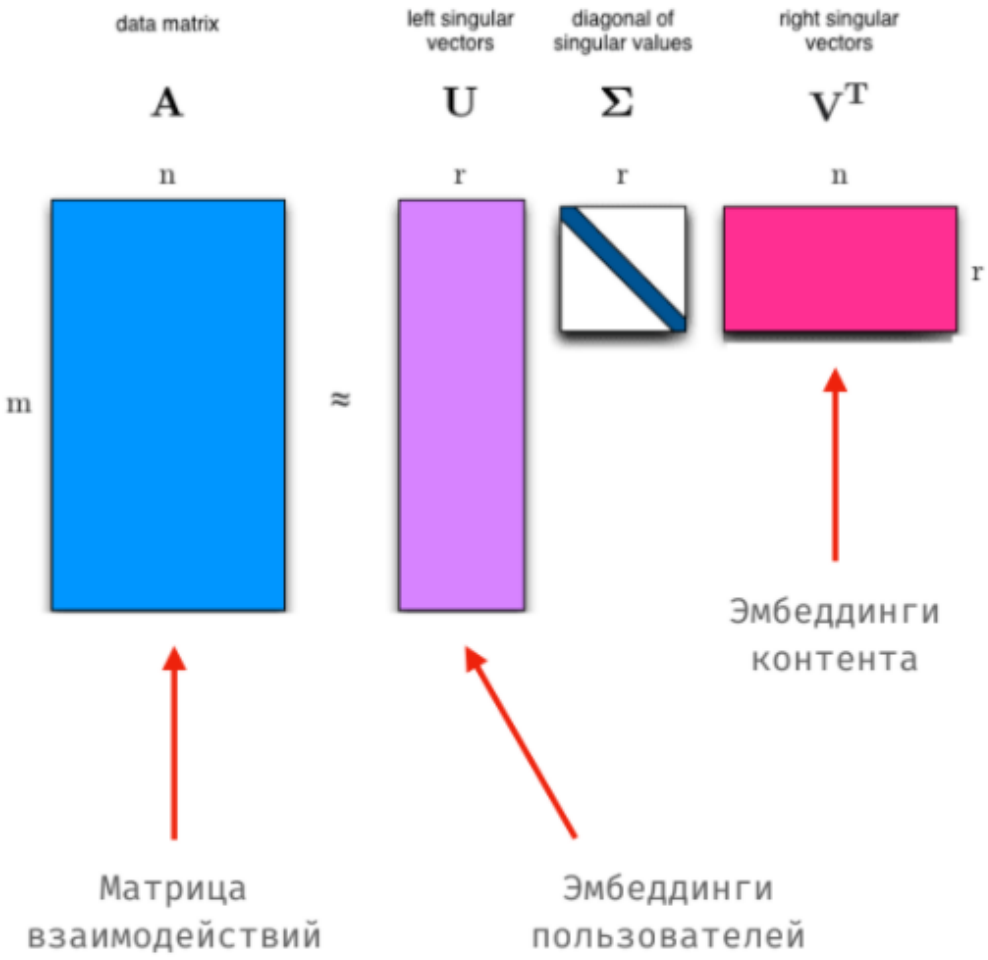

Приложения SVD

- Усеченное SVD-разложение ранга r матрицы взаимодействий позволяет получить эмбеддинги размерности r как для пользователей, так и для контента!
- Более того: чем больше скалярное произведение эмбеддингов пользователя и контента, тем выше шанс, что пользователю понравится контент!
- Это позволяет построить простейшую рекомендательную систему!

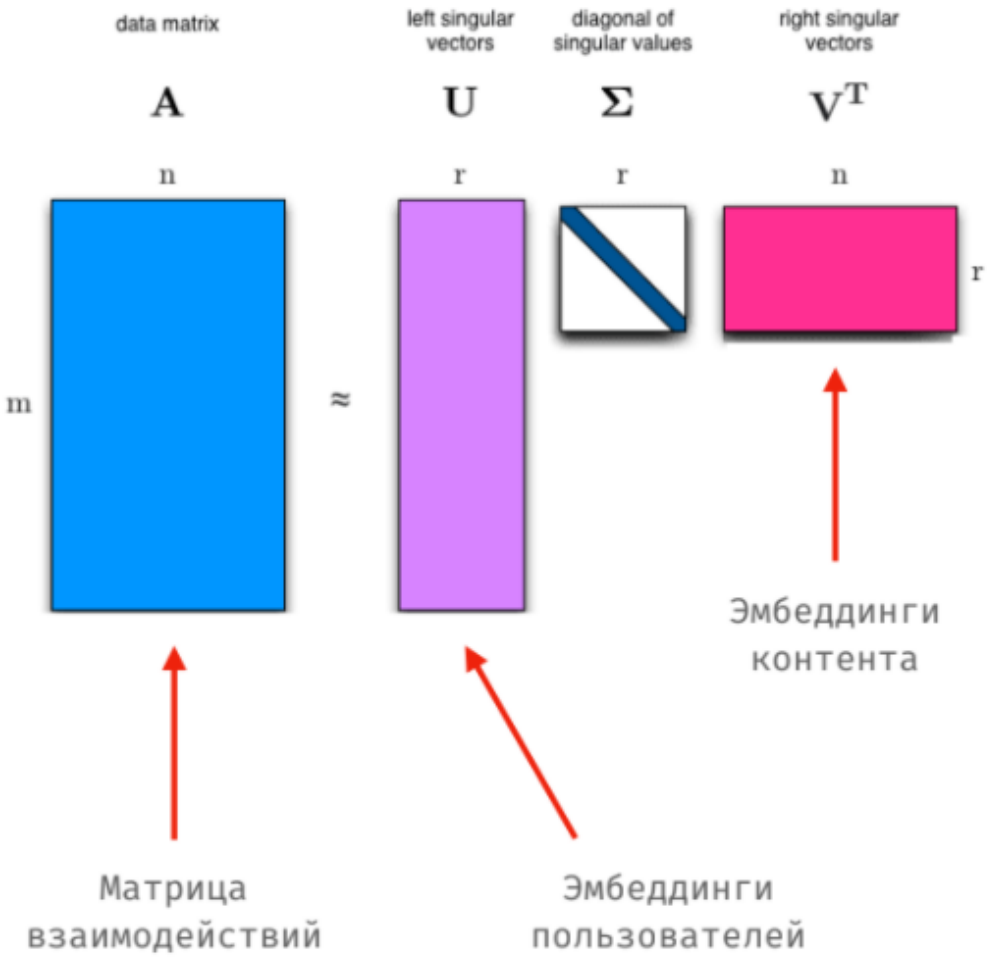

Приложения SVD

- Рекомендательные системы на основе коллаборативной фильтрации — основа рекомендательных систем в Яндексе — в рекламе, Дзене и т.д.

Приложения SVD

- Рекомендательные системы на основе коллаборативной фильтрации — основа рекомендательных систем в Яндексе — в рекламе, Дзене и т.д.
- Разумеется, там используются более продвинутые матричные факторизации.
- Но идея та же!

Приложения SVD

- Кроме того, SVD-разложение можно использовать как механизм сжатия изображений и видео…

Detail from Durer's Melancolia, dated 1514., 359x371 image

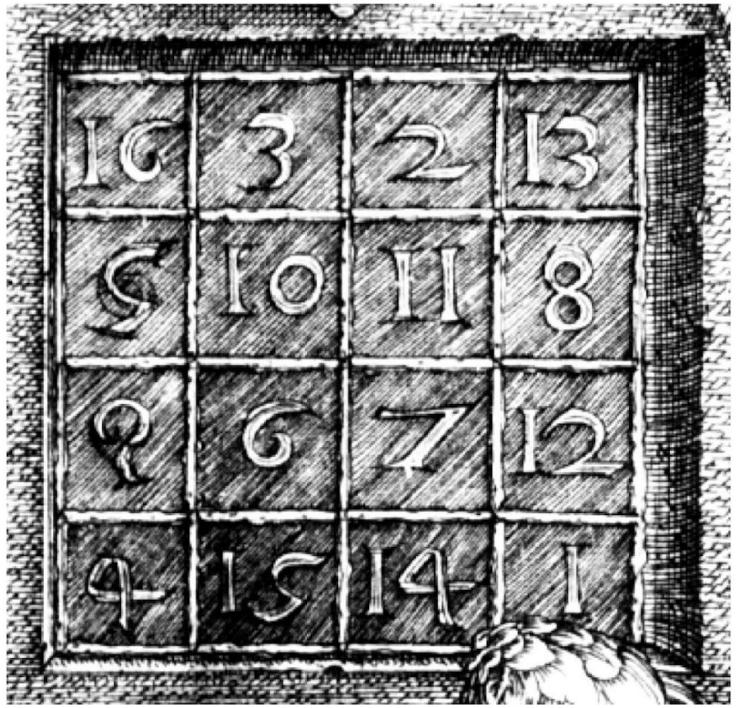

EOF reconstruction with 50 modes

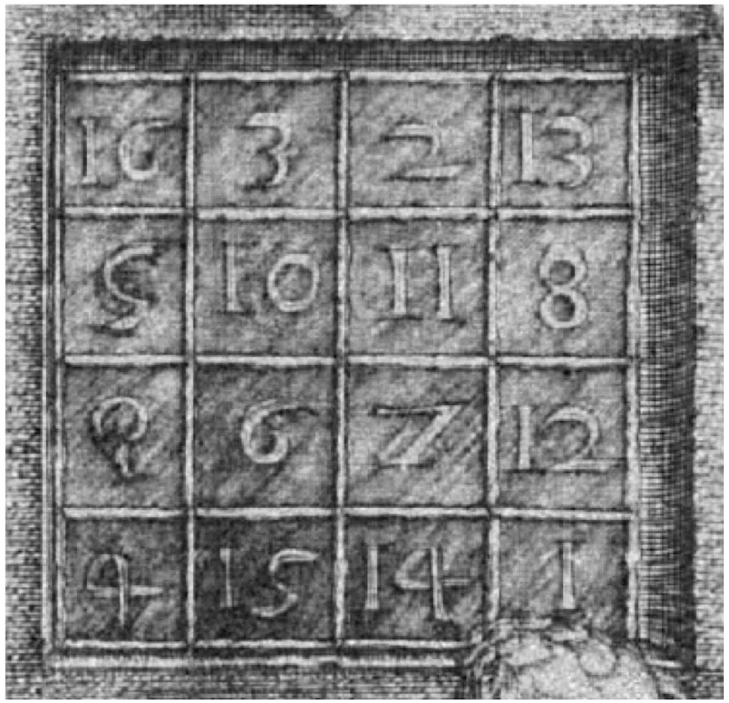

Приложения SVD

Конечно же, мы еще вернемся к этому на семинарах!

- Кроме того, SVD-разложение можно использовать как механизм сжатия изображений и видео…

Detail from Durer's Melancolia, dated 1514., 359x371 image

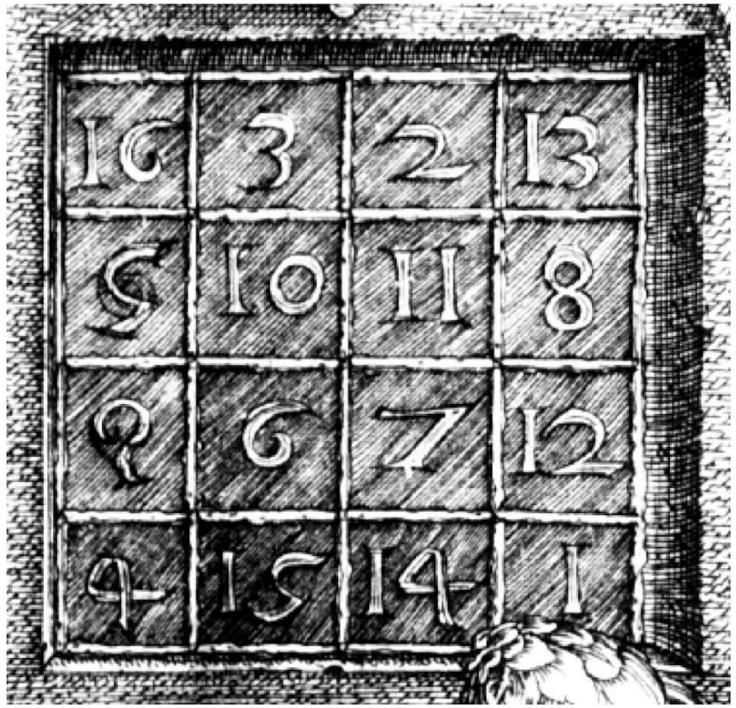
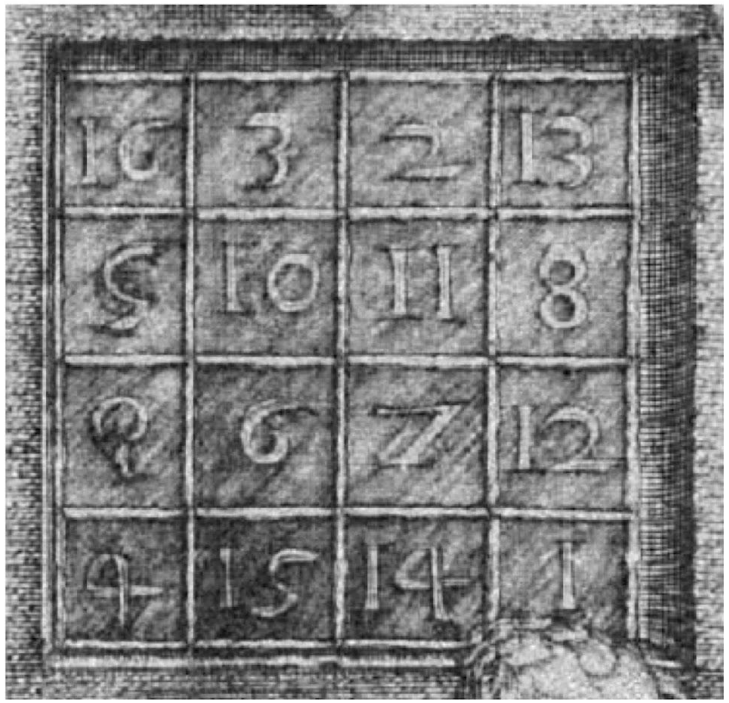
EOF reconstruction with 50 modes